


파일럿 프로젝트 (빅데이터 플랫폼 프로젝트)

전국 빵집현황 정보 분석

2026.08.06

이창희



KOREATECH
직업능력심사평가원



고용노동부

Contents

- ① 프로젝트 개요
- ② 프로젝트 수행 절차 및 방법
- ③ 프로젝트 수행 결과
- ④ 자체 평가 의견

프로젝트 개요

프로젝트 주제 및 선정 배경

전국 빵집 데이터를 수집·시각화하여 가격 분포, 인기 메뉴, 지역별 분포 현황을 분석. 소비자 관점에서 지역별 빵집 접근성과 가격대를 한눈에 파악할 수 있는 대시보드가 필요하다고 판단하여 기획.

프로젝트 개요

크롤링으로 수집한 전국 빵집 데이터를 Kibana 대시보드로 시각화. 가격 통계, 대표 메뉴 워드클라우드, 지역별 분포 지도 등 총 8개 패널로 구성하여 데이터를 다각도로 분석.

활용 장비 및 재료

데이터 수집: 문화빅데이터플랫폼에서 CSV 파일로 수집
개발 환경: R, Kibana(Elasticsearch 연동 시각화)

프로젝트 구조

문화빅데이터플랫폼에서 CSV 데이터 수집 R로 데이터 가공
Elasticsearch 적재 Kibana 대시보드 시각화 인사이트 도출

기대 효과

지역별 빵집 밀집도 및 가격 트렌드 파악
데이터 기반 의사결정(창업 입지, 가격 책정 등) 참고자료 제공

프로젝트 일정

①

8월 3일

주제 및 개발 도구 선정

②

8월 3일~ 8월 4일

데이터준비

③

8월 4일~ 8월 5일

데이터 분석

④


8월 5일~ 8월 6일

데이터 시각화

⑤

8월 7일

보고서 작성



프로젝트 수행 절차 및 방법

1단계. 주제 및 개발 도구 선정

전국 빵집 현황 분석을 주제로 선정. 시각화 도구는 R, Kibana(Elasticsearch)로 결정

2단계. 데이터 준비

문화빅데이터플랫폼에서 전국 빵집 관련 데이터를 CSV 파일로 수집

3단계. 데이터 분석

R을 활용해 수집한 CSV 데이터 전처리
(결측치 처리, 가격·메뉴·지역 컬럼 정제)
및 기초 통계 분석

4단계. 데이터 시각화

가공된 데이터를 Elasticsearch에 적재하고 Kibana로 대시보드 구성. 가격 통계, 메뉴 워드클라우드, 지역별 분포 지도 등 8개 패널 제작

5단계. 보고서 작성

대시보드 분석 결과를 바탕으로 파워포인트 보고서 작성

프로젝트 수행 절차 및 방법



1단계. 데이터 수집

문화빅데이터플랫폼에서 전국빵집 관련 데이터를 CSV 파일로 다운로드

2단계. R — 1차 가공(지도, 막대그래프 개씩만 구성하였습니다.)

R에서 `read.csv()`로 CSV 로드 → 전화번호 필드 제거(개인정보), 위도 · 경도 숫자형 변환, 결측치 필터링 → `leaflet`으로 지도 시각화, `ggplot2`로 지역별 막대그래프까지 R 단계에서 1차 완성

3단계. Elasticsearch — 인덱싱

R에서 정제된 데이터를 Elasticsearch에 적재 → `nori_tokenizer` 기반 커스텀 분석기 설계, `text/keyword/geo_point` 등 필드별 매핑 설정 → `_reindex`로 위도/경도를 `geo_point(location)`로 통합, 전화번호 재차 제거


4단계. Kibana — 최종 시각화 (대부분 Kibana 에서 하였습니다.)

Elasticsearch에 적재된 데이터를 Kibana 대시보드로 연결 → 워드클라우드, 지도, 가격 통계, 지역 Top15 등 8개 패널 구성

즉 순서는:

CSV 수집 → R(가공+1차 시각화) → Elasticsearch(인덱싱) → Kibana(최종 대시보드)

프로젝트 수행 결과



전국빵집 대표메뉴 중 제일 많이 사용된 단어 Count

전국 대표메뉴 중 제일 많은 단어 50건중


가장 많이 사용된 단어는 우유식빵이 제일 많이 사용되고 있고있습니다

그 뒤로 밤식빵 바게트 쌀식빵 모닝빵 등 대중적으로 사람 들이 많이 식빵 류 를 많이 찾고, 메뉴 중 가장 많은 단어 입니다.

빵은 대량 구매·저장·판매가 쉬워 매장 운영이 단순하고, 한국 소비자들이 '식빵'에 익숙해 기본 메뉴로 자리 잡았다는 점이 함께 작용
한국 빵 시장에서 식빵은 '디저트' 성격의 빵으로 자리 잡았고, 단팥빵·소보로빵 등과 함께 주력 품목으로 소비됩니다.



또한 식빵은 샌드위치, 토스트 등으로 응용이 쉽고, 간편하게 먹기 좋다는 점이 반복 구매로 이어질 수 있습니다.

프로젝트 수행 결과



전국빵집 대표 메뉴와가격 합 통계 20건중
우유식빵이 19.47% 로 단어 50건중에서도 1등 메뉴와가격 합도 1등입니다.
2022년 도에 소금빵이 유행 하여 그안에 토핑 양버터를 많이 사용했다고 합니다.
또한 양버터를 호두과자에 넣어 먹는 등 응용 사례 가 많아 2등 입니다.



프로젝트 수행 결과



전국 빵집 분포도 + 지도 (2022년 12월 31일 기준)

전국 빵집 분포 지도를 보면 경기(2,771건), 경남(780건), 경북(406건) 순으로 밀집도가 높으며,
특히 경기 지역에 압도적으로 많이 분포.
지도 클릭 시 시설명·지역명·도로명주소 등 상세 정보 확인 가능.


프로젝트 수행 결과



전국 빵집 중 제일 많은 지역 15위

서울 1,501건 · 경기 1,251건으로 상위 2개 지역이 전체의 절반 가까이 차지. 3위 부산(435건)부터는 격차가 크게 벌어짐 (서울 대비 약 3.4배 차이). 4~7위(경북 424 · 경남 394 · 인천 305 · 충남 258)는 200~400건대로 완만하게 감소하고, 8위 이하(전남 242 ~ 강원 108)는 100~250건대에서 소폭 차이로 이어짐. 수도권(서울+경기+인천) 합산 시 약 3,057건으로 전체 상위권의 절반 이상 차지하는 구조.


프로젝트 수행 결과



전국 빵집 중 가장 높은 가격을 차지하는 15위

1위 매장은 약 53,000원대로 최고가 형성, 2~5위(약 48,000~52,000원)까지는 완만한 하락,
6위부터 4,000원대로 한 단계 꺾이는 구간 존재. 이후 15위(약 33,000원)까지는 33,000~40,000원대에서 서서히 감소.
가게명 쪽으로 보아 대부분 프리미엄 디저트·수입 베이커리·호텔 계열로 추정되며,
일반 동네 빵집 가격대(1,000~5,000원)와는 10배 가까운 격차.

프로젝트 수행 결과



전국 빵집 중 낮은 가격 15위

500원부터 1,800원까지 100~200원 단위로 정확히 계단식 분포(500-600-700-800-900-1,000-1,100-1,200-1,250-1,300-1,400-1,500-1,600-1,700-1,800).

가격 구간이 매우 균일하게 나뉘어 있어,
실제 최저가 판매 메뉴들이 저가 구간에서 촘촘하게 형성되어 있음을 보여줌.
편의점·재래시장형 빵집 등 저가 전략 매장의 존재 가능성 시사.

프로젝트 수행 결과



전국 빵집 메뉴 중 30건 최고값:최저값 비교

최저-최고 가격 차가 가장 큰 메뉴는 마늘빵(최저 약 300원 → 최고 약 8,000원, 약 27배 차이)과 몽블랑(약 2,800원 → 7,600원).


반면 슈크림빵·마들렌·단팥빵 등은 최저-최고 격차가 2,000~2,500원 수준으로 상대적으로 가격이 안정적. 전반적으로

대부분 메뉴가 최저 대비 최고가가 2~4배 수준이나,

마늘빵·몽블랑처럼 프리미엄화가 심한 메뉴는 격차가 훨씬 크게 벌어짐 ,

동일 메뉴명이어도 매장별 재료·브랜드에 따라 가격 편차가 큰 품목군으로 해석 가능


프로젝트 수행 결과



전국 빵집 가격 통계


가격대별 매장 수 분포: 3,000원대 248건(최다), 3,500원대 225건,
4,000원대 221건, 2,500원대 188건,
4,500원대 183건. 2,500~4,500원 구간에 매장이 집중적으로 몰려 있으며,
특히 3,000원대가 가장 보편적인 빵 가격대로 확인됨

프로젝트 수행 결과



대시보드 종합 화면 (좌측)

대표메뉴 워드클라우드, 전국/부산 지도, 메뉴-가격 도넛 통계, 지역 Top15, 최저가 Top15까지 6개 패널을 한 화면에 배치한 종합 대시보드.



대시보드 종합 화면

최저가 바차트, 메뉴 30건 최고-최저 비교, 가격 통계 카드(248/225/221/188/183)를 배치한 나머지 패널.

프로젝트 수행 결과

```
## 검색 할일 완료 ##
DELETE /bakeshop

GET /bakeshop
GET /bakeshop/_count
GET /bakeshop/_search

# 인덱스 재생성
PUT /bakeshop2
{
  "settings": {
    "analysis": {
      "filter": {
        "bakeshop_stop": {
          "type": "stop",
          "stopwords": ["은", "는", "이", "가", "을", "를",
                        "에", "의", "와", "과", "도", "로",
                        "에서", "하다"]
        },
        "min_length_2": {
          "type": "length",
          "min": 2
        }
      },
      "analyzer": {
        "bakeshop_analyzer": {
          "tokenizer": "nori_tokenizer",
          "filter": [
            "nori_part_of_speech",
            "nori_readingform",
            "lowercase",
            "stop",
            "stemmer",
            "bakeshop_stop",
            "min_length_2"
          ]
        }
      }
    },
    "mappings": {
      "properties": {
        "시점명": {
          "type": "text",
          "analyzer": "bakeshop_analyzer",
          "fields": {
            "keyword": {
              "type": "keyword",
              "ignore_above": 256
            }
          }
        },
        "도로명주소": {
          "type": "text",
          "analyzer": "bakeshop_analyzer",
          "fields": {
            "keyword": {
              "type": "keyword",
              "ignore_above": 256
            }
          }
        }
      }
    }
  }
}
```

인덱스 재생성 및 커스텀 분석기 정의
DELETE /bakeshop → 기존 인덱스 삭제 (재설계 전 초기화)
PUT /bakeshop2 → 새 인덱스 생성하면서
settings에 분석기 정의
bakeshop_stop 필터: 한국어 조사/어미
(은,는,이,가,을,를,에,의,과,도,에서,하다 등)를
불용어로 지정해 제거 →
검색 시 "빵집이"와 "빵집" 같은 조사 차이로 검색 누락되는 걸 방지
min_length_2 필터: 2글자 미만 토큰 제거 → 의미 없는 한 글자 토큰
(조사 잔여물 등) 걸러냄
bakeshop_analyzer:
tokenizer: nori_tokenizer → 한국어 형태소 분석기(은/는/이/가 같
은 조사를 분리 인식)
filter 체인: 품사 정보 추출(nori_part_of_speech) → 원형 변환
(nori_readingform) →
소문자화(lowercase) → 불용어 제거(stop) → 커스텀 불용어
(bakeshop_stop) →
최소길이 필터(min_length_2) 순서로 적용

```
},
"도로명주소": {
  "type": "text",
  "analyzer": "bakeshop_analyzer",
  "fields": {
    "keyword": {
      "type": "keyword",
      "ignore_above": 256
    }
  }
},
"대표메뉴": {
  "type": "text",
  "analyzer": "bakeshop_analyzer",
  "fields": {
    "keyword": {
      "type": "keyword",
      "ignore_above": 256
    }
  }
},
"지역명": {
  "type": "text",
  "analyzer": "bakeshop_analyzer",
  "fields": {
    "keyword": {
      "type": "keyword",
      "ignore_above": 256
    }
  }
},
"홈페이지주소": {
  "type": "keyword"
},
"전화번호": {
  "type": "keyword"
},
"location": {
  "type": "geo_point"
},
"메뉴가격": {
  "type": "integer"
},
"기준일자": {
  "type": "keyword"
},
"message": {
  "type": "text",
  "analyzer": "bakeshop_analyzer"
}
}
}

POST _reindex
{
  "source": {
    "index": "bakeshop",
    "type": "bakeshop"
  },
  "target": {
    "index": "bakeshop2",
    "type": "bakeshop2"
  }
}
```

인덱스 재생성 및 커스텀 분석기 정의
DELETE /bakeshop → 기존 인덱스 삭제 (재설계 전 초기화)
PUT /bakeshop2 → 새 인덱스 생성하면서 settings에 분석기 정
의
bakeshop_stop 필터: 한국어 조사/어미(은,는,이,가,을,를,에,의,
과,도,에서,하다 등)를 불용어로 지정해 제거 → 검색 시 "빵집
이"와 "빵집" 같은 조사 차이로 검색 누락되는 걸 방지
min_length_2 필터: 2글자 미만 토큰 제거 → 의미 없는 한 글자
토큰(조사 잔여물 등) 걸러냄
bakeshop_analyzer:
tokenizer: nori_tokenizer → 한국어 형태소 분석기(은/는/이/가
같은 조사를 분리 인식)
filter 체인: 품사 정보 추출(nori_part_of_speech) → 원형 변환
(nori_readingform) → 소문자화(lowercase) → 불용어 제거
(stop) → 커스텀 불용어(bakeshop_stop) → 최소길이 필터
(min_length_2) 순서로 적용

프로젝트 수행 결과

데이터 재인덱싱 및 정제 작업

1) _reindex — 인덱스 이전 + 좌표 병합

bakeshop 인덱스를 bakeshop2로 복사하면서 script로 데이터 가공
원본에 위도, 경도 필드가 각각 따로 있었는데, 두 값이 모두 존재할
때(!= null) location이라는 geo_point 형식(lat/lon)으로 합침
병합 후 원본 위도, 경도 필드는 remove()로 삭제 → 불필요한 중복
필드 정리

2) 확인용 쿼리

DELETE /bakeshop2, GET /bakeshop2, /bakeshop2/_count,
/bakeshop2/_search → 재인덱싱 전후 인덱스 상태·문서 수 점검용
명령어들

3) 전화번호 필드 제거

POST bakeshop2/_update_by_query + script로 모든 문서에서 전
화번호 필드를 일괄 삭제
CSV 원본부터 있던 전화번호 데이터를 개인정보 보호 차원에서 인덱
스에서 제거한 작업

4) 제거 확인

GET /bakeshop2/_search에서 "_source": "전화번호"로 검색 → 남
아있는 값 있는지 확인
"_source": ["기준일자", "location"]로 특정 필드만 뽑아 값 정상 여
부 확인

5) 형태소 분석 테스트 (_analyze)

앞서 만든 bakeshop_analyzer가 실제 주소·메뉴·가격 텍스트를 어떻
게 토큰화하는지 테스트
예시 텍스트: "오일조밀,경기 시흥시 목감출레로 80 오일조
밀,41.41390,126.847971,37.370576,경기,,,밤식빵 .6000원 .20221231"
→ 이런 원본 문자열이 분석기를 거쳐 어떤 토큰들로 쪼
개지는지 검증하는 단계

6) 데이터 검색 확인

GET /bakeshop2/_search로 message 필드만 3건 조회
위 재인덱싱·정제 작업이 실제로 반영됐는지 원본 메시지 필드 샘
플 확인하는 검증 쿼리

```
POST _reindex
{
  "source": {
    "index": "bakeshop"
  },
  "dest": {
    "index": "bakeshop2"
  },
  "script": {
    "source": """
    if (ctx._source['위도'] != null && ctx._source['경도'] != null) {
      ctx._source.location = [
        'lat': ctx._source['위도'],
        'lon': ctx._source['경도']
      ];
    }
    ctx._source.remove('위도');
    ctx._source.remove('경도');
    """
  }
}
DELETE /bakeshop2
GET /bakeshop2
GET /bakeshop2/_count
GET /bakeshop2/_search

# 전화 번호 제거(csv 파일부터 전부 NULL 값)
POST bakeshop2/_update_by_query
{
  "script": {
    "source": """
    | ctx._source.remove('전화번호');
    """
  }
}
GET /bakeshop2/_search
{
  "_source": "전화번호",
  "size": 1
}

GET /bakeshop2/_search
{
  "_source": [
    "기준일자",
    "location"
  ]
}

# 토큰 분석
GET /bakeshop2/_analyze
{
  "text": "오일조밀,경기 시흥시 목감출레로 80 오일조밀,41.41390,126.847971,37.370576,경기,,,밤식빵 .6000원 .20221231",
  "analyzer": "bakeshop_analyzer"
}

GET /bakeshop2/_search
{
  "_source": [
    "message"
  ],
  "size": 3
}
```

프로젝트 수행 결과

```
setwd('c:/R/bakeshop')
getwd()
bakeshop <- read.csv(
  "bakeshop.csv",
  fileEncoding = "UTF-8",
  stringsAsFactors = FALSE
)
head(bakeshop)

str(bakeshop)

bakeshop$TEL_NO <- NULL
bakeshop$FCLTY_LO <- as.numeric(bakeshop$FCLTY_LO)
bakeshop$FCLTY_LA <- as.numeric(bakeshop$FCLTY_LA)

bakeshop_map <- bakeshop[
  !is.na(bakeshop$FCLTY_LO) &
  !is.na(bakeshop$FCLTY_LA),
]
#####

##      전국 빵집 지도 표현      ##
library(leaflet)
# install.packages("leaflet.extras")

bakeshop_map$REPRSNT_MENU_NM[
  bakeshop_map$REPRSNT_MENU_NM == ""
] <- "정보없음"

bakeshop_map$MENU_PRC[
  bakeshop_map$MENU_PRC == ""
] <- "정보없음"

bakeshop_map$popup <- paste0(
  "<b>시설명 : </b>", bakeshop_map$FCLTY_NM,
  "<br>",
  "<b>주소 : </b>", bakeshop_map$RDNMADR_NM,
  "<br>",
  "<b>메뉴 : </b>", bakeshop_map$REPRSNT_MENU_NM,
  "<br>",
  "<b>가격 : </b>", bakeshop_map$MENU_PRC
)

leaflet(bakeshop_map) %>%
  addTiles() %>%
  addAwesomeMarkers(
    lng = ~FCLTY_LO,
    lat = ~FCLTY_LA,
    icon = awesomeIcons(
      icon = "cutlery",
      markerColor = "brown",
      iconColor = "white"
    ),
    clusterOptions = markerClusterOptions(),
    popup = ~popup
  )
#####
```

데이터 불러오기 + 전국 빵집 지도 표현

1) 데이터 로드 및 전처리

setwd()로 작업 디렉토리 지정 후 bakeshop.csv를 UTF-8 인코딩으로 읽어들임 (stringsAsFactors = FALSE로 문자열이 factor로 자동 변환되는 것 방지)

TEL_NO(전화번호) 필드를 NULL 처리 → R 단계에서도 개인정보 제거 위도(FCLTY_LA)·경도(FCLTY_LO)를 숫자형(as.numeric)으로 변환 위도/경도 값이 결측치(NA)가 아닌 행만 필터링해서 bakeshop_map으로 분리 → 지도에 찍을 수 없는 좌표 없는 데이터 제외

2) 결측 텍스트 처리

대표메뉴(REPRSNT_MENU_NM)나 가격(MENU_PRC)이 빈 값("")인 경우 "정보없음" 문자열로 채움 → 지도 팝업에 빈칸 대신 안내 문구 표시

3) 팝업 내용 구성

paste0()으로 시설명·주소·메뉴·가격을 HTML ,
 태그로 조합해 지도 클릭 시 뜨는 팝업 텍스트 생성

4) leaflet 지도 생성

leaflet() + addTiles()로 기본 지도 타일 로드
addAwesomeMarkers()로 좌표마다 마커 표시, 아이콘은 커트러리 (칼/포크) 모양, 갈색 배경에 흰색 아이콘
clusterOptions = markerClusterOptions() → 마커가 많을 때 자동으로 숫자 클러스터로 묶어서 표시(줌 아웃 시 지역별 개수 버블로 보임)
popup = ~popup → 위에서 만든 팝업 내용 연결

프로젝트 수행 결과

```
#####  
## 전국 빵집 막대 그래프 표현 ##  
library(ggplot2)  
  
area_count <- table(bakeshop$AREA_NM)  
area_count <- as.data.frame(area_count)  
colnames(area_count) <- c("지역명", "빵집 수")  
  
top15_area <- area_count[  
  order(area_count$빵집 수, decreasing = TRUE),  
][1:15, ]  
  
pastel_colors <- colorRampPalette(  
  c("#FFD1DC", "#BAE1FF", "#BAFFC9", "#FFFFBA", "#FFF1A3")  
) (15)  
  
# 막대 그래프  
ggplot(  
  top15_area,  
  aes(  
    x = reorder(`지역명`, `빵집 수`),  
    y = `빵집 수`,  
    fill = `지역명`  
  )  
)+  
  geom_bar(  
    stat = "identity"  
  ) +  
  coord_flip() +  
  scale_fill_manual(  
    values = pastel_colors  
  ) +  
  labs(  
    title = "빵집 수 TOP 15",  
    x = "지역",  
    y = "빵집 수"  
  ) +  
  theme_minimal() +  
  theme(  
    legend.position = "none"
```

지역별 빵집 수 막대그래프 (ggplot2)

1) 지역별 집계

table(bakeshop\$AREA_NM)으로 지역명별 빈도 계산 → 데이터프레임으로 변환, 컬럼명을 "지역명", "빵집 수"로 지정

2) 상위 15개 추출

order(area_count\$빵집 수, decreasing = TRUE)로 내림차순 정렬 후 상위 15개 행만 추출

3) 커스텀 컬러 팔레트

colorRampPalette()로 5가지 파스텔톤 헥스코드(핑크·연블루·민트 블루·연노랑·살구) 기반 그라데이션 15색 생성

4) 막대그래프

ggplot() + geom_bar(stat="identity")로 지역별 빵집 수 막대그래프
coord_flip()으로 가로 막대 형태 전환
scale_fill_manual()로 위에서 만든 파스텔 팔레트 적용
theme_minimal() + 범례 숨김(legend.position = "none")으로 깔끔한 스타일

자체 평가 의견

잘된 점

문화빅데이터플랫폼 CSV 원본 데이터를 R로 정제하고 Elasticsearch/Kibana로 연동해,
수집부터 시각화까지 전체 파이프라인을 직접 구축해본 경험
nori_tokenizer 기반 커스텀 분석기를 설계해 한국어 텍스트(주소·메뉴명) 검색 정확도를 높인 점
가격, 지역, 메뉴 등 다각도 시각화를 통해 수도권 밀집, 가격 편차 등 유의미한 인사이트 도출

아쉬운 점 / 어려웠던 부분

위도·경도 결측치, 빈 메뉴/가격 값 등 원본 데이터 정제에 예상보다 많은 시간 소요
Elasticsearch 매핑 설계(text/keyword/geo_point 구분) 및 분석기 설정 과정에서 시행착오 발생
일정상(8/3~8/7) 짧은 기간이라 심화 분석(상관관계 등)까지는 다루지 못함

향후 개선 방향

기준일자(2022.12.31) 외 최신 데이터 업데이트 및 시계열 비교 분석 추가
가격대별·메뉴별 소비자 리뷰 데이터 등 추가 지표 연계 가능성 검토
대시보드를 정적 캡처가 아닌 실시간 대시보드 형태로 공유하는 방안 고려

감사합니다!

